
COMPARAÇÃO ENTRE SVM SUPERVISIONADA E ONE-CLASS SVM PARA DETECÇÃO INTER-PACIENTE DE ANOMALIAS EM BATIMENTOS ECG

Juliano Eleno Silva Pádua*

Grupo 6, Processamento Digital de Sinais
Universidade Federal de São Carlos

Pedro Arthur Verger Paulino†

Grupo 6, Processamento Digital de Sinais
Universidade Federal de São Carlos

Matheo Sebastian Duarte Davalos‡

Grupo 6, Processamento Digital de Sinais
Universidade Federal de São Carlos

Ricardo Jose Ferrari§

Docente da disciplina
Universidade Federal de São Carlos

6 de julho de 2026

ABSTRACT

A detecção inter-paciente de anomalias em ECG depende tanto da representação do batimento quanto da informação disponível no treino. A análise usa a MIT-BIH Arrhythmia Database em formato WFDB, com preferência pelo canal MLII, janelas de 0,25 s antes e 0,45 s depois da anotação, exclusão dos registros paced-heavy 102, 104, 107 e 217, e avaliação binária em que N representa normalidade e os demais símbolos válidos representam anomalia. O sinal de entrada é sempre o ECG filtrado por uma cadeia FIR de fase zero com passa-alta em 0,5 Hz e passa-baixa em 40 Hz. A representação final reúne 18 features distribuídas em quatro grupos, sendo seis descritores morfológicos, três features rítmicas de intervalo RR, quatro descritores espectrais e cinco respostas Gabor extraídas do banco consolidado no notebook do grupo, com 8 Hz para P, 15 Hz para QRS e 6 Hz para T. A comparação opõe uma SVM supervisionada treinada com normais e anômalos do conjunto DS1 e uma One-Class SVM treinada apenas com batimentos normais do mesmo conjunto. A PR-AUC ocupa o papel principal, acompanhada de ROC-AUC, precision, recall, F1 e matriz de confusão. No teste DS2, a SVM supervisionada atingiu PR-AUC de 0,528, ROC-AUC de 0,748 e F1 de 0,412, enquanto a One-Class SVM atingiu PR-AUC de 0,448, ROC-AUC de 0,537 e F1 de 0,370. A formulação one-class recuperou ligeiramente mais anomalias no limiar adotado, mas ao custo de um volume muito maior de falsos positivos. A comparação mostra que a representação filtrada final é informativa, porém o acesso a exemplos anômalos no treino continua decisivo para estabilizar a fronteira inter-paciente.

1 Introdução

O eletrocardiograma reúne informação morfológica, rítmica e espectral em uma série temporal curta e biologicamente estruturada. Um protocolo automático que pretende separar batimentos normais de batimentos anômalos precisa preservar o alinhamento com o R-peak, estabilizar a linha de base e produzir descritores que continuem legíveis depois

*E-mail julianopadua@estudante.ufscar.br.

†E-mail pedropaulino@estudante.ufscar.br.

‡E-mail matheo@estudante.ufscar.br.

§E-mail rferrari@ufscar.br.

da classificação. A MIT-BIH Arrhythmia Database permanece adequada para esse objetivo por oferecer sinais reais, anotações públicas e acesso padronizado por WFDB [Moody and Mark, 2001, Goldberger et al., 2000, Moody et al., 2022].

Morfologia de batimento e intervalos RR seguem entre os descritores mais interpretáveis em estudos com separação inter-paciente entre treino e teste [de Chazal et al., 2004, Doquire et al., 2011, Mousavi and Afghah, 2019]. O interesse aqui não é apenas medir uma acurácia global, mas organizar uma representação compacta que preserve a fisiologia do traçado filtrado e permita comparar dois regimes de treinamento sob o mesmo vetor de entrada. Por essa razão, nenhuma feature é extraída do sinal bruto. Toda a modelagem parte de um ECG previamente filtrado e alinha descritores morfológicos, contexto RR, informação espectral e respostas Gabor localizadas em regiões aproximadas de P, QRS e T.

A comparação entre SVM supervisionada e One-Class SVM surge de uma assimetria recorrente em dados biomédicos. A formulação supervisionada explora exemplos normais e anômalos no ajuste e funciona como referência para o que o mesmo conjunto de features consegue oferecer quando há rótulos completos. A formulação one-class, em contraste, aprende apenas a distribuição dos batimentos normais e testa se o afastamento dessa região já basta para ranquear anomalias [Cortes and Vapnik, 1995, Scholkopf et al., 2001, Pimentel et al., 2014]. As duas leituras respondem a perguntas diferentes, e a distância entre elas deve ser interpretada como diferença de informação disponível no treino, não apenas como troca de algoritmo.

O recorte permanece binário e metodológico. O protocolo não diagnostica classes clínicas específicas nem tenta reproduzir um fluxo hospitalar completo. O rótulo N representa normalidade, enquanto os demais símbolos válidos de batimento entram como anomalia apenas para avaliação. Essa redução concentra a análise na pergunta de DSP e evita misturar o estudo com classificação multi-classe de arritmias.

A representação final foi consolidada a partir do notebook do grupo e reúne 18 features filtradas, com seis descritores morfológicos, três features rítmicas, quatro descritores espectrais e cinco respostas Gabor. A pergunta central passa a ser direta. Dado esse vetor final, até que ponto a SVM supervisionada e a One-Class SVM mantêm desempenho útil no split inter-paciente DS1-DS2.

A PR-AUC ocupa o papel central porque a classe anômala é minoritária e o custo de falsos positivos aparece diretamente na precision [Davis and Goadrich, 2006]. ROC-AUC, recall, F1 e matrizes de confusão entram como leitura complementar do regime operacional. O objetivo, portanto, é comparar os dois modelos sob a mesma representação filtrada final e verificar quanto da separação inter-paciente depende do acesso prévio a anomalias no treino.

2 Fundamentação teórica

2.1 ECG, morfologia e alinhamento por anotação

Um batimento ECG típico reúne onda P, complexo QRS e onda T em escalas temporais diferentes. A anotação de batimento da MIT-BIH funciona, portanto, como âncora para uma janela fixa que preserve a vizinhança do QRS e ainda retenha trechos nos quais P e T podem aparecer. A Figura 1 resume as regiões aproximadas usadas para organizar as features locais. Em tarefas de batimento isolado, descritores morfológicos e intervalos RR continuam relevantes porque preservam leitura fisiológica do traçado e do contexto rítmico [de Chazal et al., 2004, Doquire et al., 2011].

2.2 Filtragem FIR para morfologia de batimento

Sinais ambulatoriais de ECG acumulam deriva de linha de base, ruído muscular e interferência de rede. Quando a pergunta experimental se concentra em batimento segmentado e localização do QRS, uma banda reduzida costuma preservar a estrutura mais útil e reduzir componentes lentas ou muito rápidas. Thakor et al. mostraram que a energia discriminativa do QRS se concentra em frequências intermediárias, com separação relevante em torno de 17 Hz [Thakor et al., 1984]. Elgendi et al. indicaram que a faixa de 0,5 a 40 Hz preserva componentes centrais do QRS em aplicações de detecção e processamento eficiente [Elgendi et al., 2017]. Butt et al. também reforçam a utilidade de cadeias voltadas a deriva e ruído de rede em ECG ambulatorial [Butt et al., 2020]. A escolha por FIR linear com aplicação em fase zero atende ainda a uma exigência prática do protocolo. Como o R-peak ancora a segmentação e as janelas fisiológicas usadas nas features, deslocamentos de fase prejudicariam a comparação. Essas referências sustentam a decisão de extrair features apenas após a filtragem FIR, evitando que os modelos operem sobre descritores ainda contaminados por ruído que já pode ser tratado na entrada.




Figura 1: Batimento ECG com onda P, complexo QRS, onda T, R-peak e janelas aproximadas usadas na extração de features.

2.3 Descritores espectrais e banco Gabor compacto

O espectro de um batimento não substitui a morfologia, mas ajuda a resumir quão rápidas ou espalhadas são as transições do sinal. Centróide espectral, largura de banda e energia em faixas relacionadas ao QRS acrescentam uma leitura global que não depende apenas do pico local. A STFT organiza essa ideia como análise local em tempo e frequência. Para um sinal discreto $x[n]$,

$$X(m, \omega) = \sum_n x[n] w[n - m] e^{-j\omega n},$$

em que w é a janela de análise.

Filtros de Gabor 1D seguem a mesma lógica de localização conjunta em tempo e frequência, usando uma senoide modulada por envoltória gaussiana [Gabor, 1946]. Essa família já foi empregada em extração de features de ECG [Lee et al., 2012] e aparece em representações tempo-frequência mais recentes [Eltrass et al., 2021]. O protocolo não usa uma malha extensa de frequências. Em vez disso, reaproveita o banco compacto consolidado no notebook, com um filtro par em 8 Hz para a região P, um filtro em magnitude em 15 Hz para QRS e um filtro par em 6 Hz para T. A escolha privilegia interpretabilidade, controle de dimensionalidade e coerência com a segmentação ancorada no R-peak.

2.4 SVM supervisionada e One-Class SVM

A SVM supervisionada procura uma fronteira de margem máxima entre duas classes [Cortes and Vapnik, 1995]. Na formulação com folgas, o problema pode ser escrito como

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_i \xi_i \quad \text{sujeito a} \quad y_i (w^\top \phi(x_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

Essa formulação aproveita diretamente exemplos normais e anômalos no treino e funciona, neste protocolo, como referência para o mesmo conjunto de features.

One-Class SVM estima a região de suporte da distribuição normal [Scholkopf et al., 2001]. A formulação primal busca separar os exemplos normais da origem no espaço de features,

$$\min_{w, \rho, \xi} \frac{1}{2} \|w\|^2 + \frac{1}{\nu n} \sum_i \xi_i - \rho \quad \text{sujeito a} \quad w^\top \phi(x_i) \geq \rho - \xi_i, \quad \xi_i \geq 0.$$

Essa segunda leitura é mais próxima de detecção de novidade e evita assumir que as anomalias vistas em desenvolvimento representam todo o universo de eventos possíveis [Pimentel et al., 2014].

2.5 Split inter-paciente e métricas para desbalanceamento

A separação entre pacientes reduz estimativas otimistas decorrentes da similaridade intra-paciente, o que motivou a divisão DS1 e DS2 adotada em vários estudos com MIT-BIH [Mousavi and Afghah, 2019]. Como a classe anômala é minoritária, a curva precision-recall recebe prioridade narrativa. A PR-AUC responde diretamente à fração de falsos positivos entre os casos sinalizados, enquanto a ROC-AUC continua útil como medida complementar de discriminação [Davis and Goadrich, 2006]. Precision, recall, F1 e matriz de confusão entram como leitura em limiar fixo para cada modelo.

3 Metodologia

3.1 Base, canal e protocolo de rótulos

A MIT-BIH Arrhythmia Database reúne registros ambulatoriais de cerca de 30 minutos, amostrados a 360 Hz em dois canais [Moody and Mark, 2001, PhysioNet, 2005]. O pipeline lê os arquivos locais com WFDB, prioriza o canal MLII quando disponível e usa as anotações atr como referência temporal dos batimentos. Após a exclusão dos registros paced-heavy 102, 104, 107 e 217, o protocolo mantém 44 registros.

O rótulo binário é usado apenas na avaliação. Batimentos N formam a classe normal, enquanto os demais símbolos válidos de batimento formam a classe anômala. Símbolos técnicos, mudanças de ritmo e batimentos paced ficam fora da amostra analisável. Essa escolha preserva o foco em anomalias de batimento não-paced e evita transformar o benchmark em um detector de marcapasso.

3.2 Segmentação e filtragem do sinal de entrada

Cada linha experimental corresponde a uma janela de 0,25 s antes e 0,45 s depois da anotação. Janelas que encostam nas bordas do registro são descartadas para preservar duração constante. O sinal é filtrado no registro completo antes da segmentação, pois aplicar `filtfilt` diretamente em janelas curtas introduziria artefatos de borda.

A cadeia adotada remove primeiro a média do registro e, em seguida, aplica dois filtros FIR lineares com janela de Hamming e fase zero por forward-backward. O primeiro é um passa-alta em 0,5 Hz com largura de transição de 1 Hz e 1189 coeficientes. O segundo é um passa-baixa em 40 Hz com largura de transição de 8 Hz e 149 coeficientes. A escolha combina preservação da morfologia útil do ECG com atenuação de deriva de linha de base, ruído muscular e componentes de alta frequência [Thakor et al., 1984, Elgendi et al., 2017, Butt et al., 2020]. Como o R-peak serve de âncora para a segmentação e para as janelas fisiológicas de P, QRS e T, a filtragem em fase zero evita deslocamentos temporais que prejudicariam a interpretação local do batimento.

Nenhuma feature é extraída do sinal bruto. Todos os descritores do manuscrito partem desse sinal filtrado comum, o que reduz a influência de ruído residual na comparação entre os modelos e mantém a base fisiológica da representação.




Figura 2: Batimento normal segmentado no mesmo R-peak antes e depois da cadeia FIR.

3.3 Split inter-paciente e tamanho do dataset

Os registros do grupo DS1 formam o conjunto de treino e os registros DS2 formam o teste final. Nenhum paciente aparece nos dois lados. Depois da filtragem, da segmentação e das exclusões, o protocolo produziu 100.694 batimentos válidos. Desse total, 74.516 pertencem à classe normal e 26.178 à classe anômala. O treino contém 51.002 batimentos, com 38.088 normais e 12.914 anômalos. O teste contém 49.692 batimentos, com 36.428 normais e 13.264 anômalos.

3.4 Representação final do batimento

O vetor final reúne 18 features e altera apenas a forma de resumir o batimento filtrado e o seu contexto rítmico local. Não há descritores do sinal bruto nem expansão massiva de dimensionalidade. A intenção é manter um conjunto compacto, interpretável e coerente com a segmentação ancorada no R-peak.

Tabela 1: Grupos de features da representação final.

Grupo	Variáveis	Quantidade
Morfologia filtrada	amplitude em R, pico-a-pico, energia, área absoluta, inclinação máxima absoluta e desvio-padrão	6
Ritmo	RR anterior, RR posterior e razão RR	3
Espectrais	centroide espectral, largura de banda, potência em 8 a 20 Hz e potência em 20 a 40 Hz	4
Gabor	energia em P, energia em QRS, máximo em QRS, deslocamento do pico em QRS e energia em T	5

As features morfológicas resumem amplitude, energia, área absoluta, variabilidade e inclinação máxima do batimento filtrado. As features rítmicas capturam o contexto local do intervalo RR antes e depois da batida. Os descritores espectrais medem quão concentrada ou espalhada está a energia da janela, com ênfase nas bandas de 8 a 20 Hz e 20 a 40 Hz, associadas a componentes mais rápidas do QRS. Esse desenho mantém a comparação no domínio do sinal tratado por DSP e explicita que o vetor final usa morfologia, ritmo, espectro e respostas locais, não amostras cruas da janela.

3.5 Banco Gabor do notebook

A representação final usa exatamente o banco consolidado no notebook do grupo. A região P recebe um filtro par em 8 Hz com janela de -0,28 s a -0,07 s. A região QRS recebe um filtro em magnitude em 15 Hz com janela de -0,07 s a 0,07 s. A região T recebe um filtro par em 6 Hz com janela de 0,18 s a 0,45 s. A Figura 3 mostra os três kernels normalizados, e a Figura 4 ilustra as respostas alinhadas em um batimento normal e em um batimento anômalo.




Figura 3: Banco compacto de filtros Gabor 1D usado na representação final.




Figura 4: Respostas Gabor em um batimento normal e em um batimento anômalo, com janelas aproximadas de P, QRS e T destacadas.

3.6 Modelos e métricas

Dois modelos compartilham a mesma padronização das 18 features, mas usam regimes de treinamento diferentes. A SVM supervisionada usa kernel RBF, `class_weight=balanced`, `gamma=scale` e probabilidades habilitadas. Esse modelo é ajustado com todos os 51.002 batimentos do treino DS1. A One-Class SVM usa kernel RBF, `nu=0.05` e `gamma=scale`, sendo ajustada apenas com os 38.088 batimentos normais de DS1.

PR-AUC é a métrica principal. ROC-AUC, precision, recall, F1 e matriz de confusão complementam a análise. A SVM supervisionada é avaliada pelo escore de probabilidade da classe anômala, enquanto a One-Class SVM usa o valor negativo da `decision_function`, orientado para que escores maiores representem maior anomalia.




Figura 5: Pipeline experimental resumido.

4 Resultados

A execução completa gerou a representação final de 18 features para 100.694 batimentos válidos. A SVM supervisionada foi treinada com os 51.002 batimentos de DS1, enquanto a One-Class SVM recebeu apenas os 38.088 batimentos normais desse mesmo conjunto. O teste em DS2 manteve 49.692 batimentos, com 36.428 normais e 13.264 anômalos. A Tabela 2 resume a comparação principal.

Tabela 2: Resultados da comparação inter-paciente para a representação final.

Modelo	Treino	Features	PR-AUC	ROC-AUC	Precision	Recall	F1
SVM supervisionada	normais + anômalos de DS1	18	0.528	0.748	0.485	0.358	0.412
One-Class SVM	apenas normais de DS1	18	0.448	0.537	0.354	0.388	0.370

A SVM supervisionada superou a One-Class SVM em PR-AUC, ROC-AUC, precision e F1 na mesma representação final. A diferença de 0,080 ponto de PR-AUC mostra vantagem consistente do regime supervisionado quando há rótulos anômalos disponíveis no treino. A Figura 6 mostra que essa vantagem não depende apenas de um limiar específico, pois a SVM mantém precision mais alta ao longo da maior parte da faixa de recall observada.




Figura 6: Curvas precision-recall da SVM supervisionada e da One-Class SVM no teste inter-paciente.

O limiar operacional destaca um trade-off diferente entre os modelos. A One-Class SVM recuperou 5153 anomalias no teste, enquanto a SVM supervisionada recuperou 4753. Esse ganho de 400 verdadeiros positivos veio acompanhado de 4379 falsos positivos adicionais. A queda de precision para 0,354, frente a 0,485 na SVM supervisionada, confirma que a fronteira one-class operou de forma mais permissiva no conjunto inter-paciente.

Tabela 3: Matrizes de confusão no teste inter-paciente.

Modelo	TN	FP	FN	TP
SVM supervisionada	31385	5043	8511	4753
One-Class SVM	27006	9422	8111	5153




Figura 7: Matrizes de confusão visualizadas por proporção em cada classe real. Cada célula mostra o tipo de acerto ou erro, a contagem e o percentual da linha correspondente.

As matrizes de confusão da Tabela 3 e da Figura 7 tornam esse contraste mais direto. Entre os batimentos normais, a SVM supervisionada manteve 86,2% classificados como normais, contra 74,1% na One-Class SVM. Entre os batimentos anômalos, a One-Class SVM reconheceu 38,8%, contra 35,8% na SVM supervisionada. A pequena vantagem de recall da formulação one-class veio acompanhada de perda expressiva de especificidade.

5 Discussão

A superioridade da SVM supervisionada era esperada em termos de informação disponível no treino, mas a magnitude dessa diferença ajuda a qualificar o papel da representação final filtrada. O vetor de 18 features já é compacto e interpretável, porém a fronteira supervisionada ainda se beneficia de observar exemplos anômalos reais de DS1 para ajustar a separação entre normalidade e anomalia. A vantagem em PR-AUC, ROC-AUC e F1 sugere que a informação adicional de classe não está sendo desperdiçada pelo conjunto de descritores escolhido.

A One-Class SVM expõe uma dificuldade mais estrutural do problema. A classe normal inter-paciente não forma uma nuvem homogênea. Diferenças de morfologia, ritmo basal, amplitude e ruído residual entre pacientes tornam a região de normalidade mais espalhada do que a formulação one-class idealizada costuma assumir. Quando a fronteira se abre para acomodar essa variabilidade, parte dos batimentos anômalos é recuperada. Ao mesmo tempo, o número de falsos positivos cresce rapidamente. O resultado operacional foi claro. Para recuperar 400 anomalias adicionais, a One-Class SVM acrescentou 4379 alarmes extras no teste.

A representação adotada continua metodologicamente interessante porque combina quatro famílias de informação sem recorrer a sinal bruto ou a embeddings pouco transparentes. As features morfológicas e rítmicas mantêm leitura direta do traçado e do contexto RR. Os descritores espectrais resumem a distribuição de energia do batimento filtrado. As respostas Gabor preservam uma leitura local em janelas fisiológicas aproximadas de P, QRS e T, com banco compacto reaproveitado do notebook final do grupo. Essa composição favorece explicação e reprodutibilidade, mesmo quando o ganho estatístico depende fortemente do regime de treino.

Algumas limitações precisam permanecer explícitas. O benchmark reduz a tarefa a normal versus anomalia, embora os símbolos anômalos agreguem morfologias e origens distintas. As janelas P, QRS e T são aproximações temporais ancoradas na anotação do R-peak, não delineações clínicas precisas. Os hiperparâmetros da SVM supervisionada e da One-Class SVM também não passaram por busca nested dentro de DS1. Além disso, uma única fronteira one-class pode ser insuficiente para representar a multimodalidade da normalidade inter-paciente. Mesmo com essas restrições, a comparação já delimita com clareza o desempenho de uma representação DSP interpretável sob dois regimes de treinamento bastante diferentes.

6 Conclusão

A comparação inter-paciente mostrou que a representação final filtrada de 18 features sustenta desempenho útil tanto para SVM supervisionada quanto para One-Class SVM, mas o regime supervisionado permaneceu mais estável no

conjunto de teste. A SVM supervisionada atingiu PR-AUC de 0,528, ROC-AUC de 0,748 e F1 de 0,412. A One-Class SVM atingiu PR-AUC de 0,448, ROC-AUC de 0,537 e F1 de 0,370.

O contraste entre as matrizes de confusão ajuda a interpretar esses números. A One-Class SVM recuperou um pouco mais anomalias no limiar adotado, mas fez isso com forte aumento de falsos positivos. A SVM supervisionada, em contrapartida, ofereceu melhor equilíbrio entre triagem e carga de revisão manual.

O protocolo deixa uma referência reproduzível para extensões futuras com busca de hiperparâmetros, calibração de limiar, seleção de features e modelagens de normalidade menos rígidas que uma única fronteira global. Mesmo sem avançar para diagnóstico clínico, a comparação já mostra que uma cadeia DSP filtrada e interpretável se beneficia de forma decisiva do acesso a exemplos anômalos no treino.

Agradecimentos

Os autores reconhecem o uso auxiliar de ferramentas de IA generativa na preparação do fluxo computacional, organização bibliográfica, depuração, documentação e revisão linguística. Essas ferramentas não foram tratadas como fontes de evidência científica, autoridade metodológica ou análise autônoma.

Referências

- George B. Moody and Roger G. Mark. The impact of the mit-bih arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3):45–50, 2001. doi: 10.1109/51.932724.
- Ary L. Goldberger, Luis A. N. Amaral, Leon Glass, Jeffrey M. Hausdorff, Plamen Ch. Ivanov, Roger G. Mark, Joseph E. Mietus, George B. Moody, Chung-Kang Peng, and H. Eugene Stanley. Physiobank, physiobank, and physionet: Components of a new research resource for complex physiologic signals. *Circulation*, 101(23):e215–e220, 2000. doi: 10.1161/01.CIR.101.23.e215.
- George Moody, Tom Pollard, and Benjamin Moody. WFDB Software Package. *PhysioNet*, June 2022. doi: 10.13026/gjvw-1m31. URL <https://doi.org/10.13026/gjvw-1m31>. Version 10.7.0.
- Philip de Chazal, Maria O’Dwyer, and Richard B. Reilly. Automatic classification of heartbeats using ecg morphology and heartbeat interval features. *IEEE Transactions on Biomedical Engineering*, 51(7):1196–1206, 2004. doi: 10.1109/TBME.2004.827359.
- Gauthier Doquire, Gaetan de Lannoy, Damien Francois, and Michel Verleysen. Feature selection for interpatient supervised heart beat classification. *Computational Intelligence and Neuroscience*, 2011:643816, 2011. doi: 10.1155/2011/643816. Open-access PMC source used from local wiki raw file.
- Sajad Mousavi and Fatemeh Afghah. Inter- and intra-patient ecg heartbeat classification for arrhythmia detection: A sequence to sequence deep learning approach. In *IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 1308–1312, 2019. doi: 10.1109/ICASSP.2019.8683140.
- Corinna Cortes and Vladimir Vapnik. Support-vector networks. *Machine Learning*, 20(3):273–297, 1995. doi: 10.1007/BF00994018.
- Bernhard Scholkopf, John C. Platt, John Shawe-Taylor, Alex J. Smola, and Robert C. Williamson. Estimating the support of a high-dimensional distribution. *Neural Computation*, 13(7):1443–1471, 2001. doi: 10.1162/089976601750264965.
- Marco A. F. Pimentel, David A. Clifton, Lei Clifton, and Lionel Tarassenko. A review of novelty detection. *Signal Processing*, 99:215–249, 2014. doi: 10.1016/j.sigpro.2013.12.026.
- Jesse Davis and Mark Goadrich. The relationship between precision-recall and roc curves. In *Proceedings of the 23rd International Conference on Machine Learning*, pages 233–240, 2006. doi: 10.1145/1143844.1143874.
- Nitish V. Thakor, John G. Webster, and Willis J. Tompkins. Estimation of qrs complex power spectra for design of a qrs filter. *IEEE Transactions on Biomedical Engineering*, BME-31(11):702–706, 1984. doi: 10.1109/TBME.1984.325393.
- Mohamed Elgendi, Amr Mohamed, and Rabab Ward. Efficient ecg compression and qrs detection for e-health applications. *Scientific Reports*, 7:459, 2017. doi: 10.1038/s41598-017-00540-x.
- Muhammad Butt et al. Baseline wander and power-line interference elimination of ecg signals using efficient signal-piloted filtering. *Sensors*, 2020. Open-access PMC source used from local wiki raw file.
- Dennis Gabor. Theory of communication. *Journal of the Institution of Electrical Engineers - Part III: Radio and Communication Engineering*, 93(26):429–457, 1946.

- Gwo Giun Lee, Jhen-Yue Hu, Chun-Fu Chen, and Huan-Hsiang Lin. Gabor feature extraction for electrocardiogram signals. In *2012 IEEE Biomedical Circuits and Systems Conference*, pages 304–307, 2012. doi: 10.1109/BioCAS.2012.6418436.
- Ahmed S. Eltrass, Mazhar B. Tayel, and Abeer I. Ammar. A new automated cnn deep learning approach for identification of ecg congestive heart failure and arrhythmia using constant-q non-stationary gabor transform. *Biomedical Signal Processing and Control*, 65:102326, 2021. doi: 10.1016/j.bspc.2020.102326.
- PhysioNet. Mit-bih arrhythmia database v1.0.0, 2005. URL <https://www.physionet.org/content/mitdb/1.0.0/>. Accessed 2026-06-06.